


Ethisch Intelligente Systems

Christoph Benz Müller

FU Berlin | U Luxembourg




Tag der offenen Tür, DCLMR, FU Berlin, 4. Juni 2019

Ethics

Koexistenz mit **Intelligenten Autonomen Systemen (IASs)**?


- ▶ geeignete **Kontrollmechanismen** für IASs
- ▶ geeignete Form der **Mensch-Maschinen-Interaktion**



Ethics

Koexistenz mit **Intelligenten Autonomen Systemen (IASs)**?

- ▶ geeignete **Kontrollmechanismen** für IASs
- ▶ geeignete Form der **Mensch-Maschinen-Interaktion**



Existierende gesellschaftliche Prozesse basieren auf:


- ▶ **Erklärungen, rationaler Argumentation & Dialog,**
- ▶ inklusive **explizitem normativem Schließen** (rechtlich & ethisch)

Entwicklung von IASs ohne solche Kompetenzen? Wie sinnvoll?

Ethics


Ethisch Intelligente Systeme — Geht das überhaupt?


- ▶ **“Echte”, eigenständige ethische Intelligenz?** Wohl kaum ...
... und das ist auch vielleicht gar nicht wünschenswert.
- ▶ **Motivation:** Kontrolle von IASs durch ...
... rechtliche & ethische Rahmenbedingungen die **wir** vorgeben!








IAS
















Pseudo-Ethische IAS (Vertrauenswürdige KI)





Verwandte Arbeiten

- ▶ Artificial Moral Agents
 - ▶ [Wallach&Allen, 2008]
- ▶ Ethical Governors
 - ▶ [ArkinEtAl., 2009, 2012]
 - ▶ [Dennis&Fisher, 2017]
- ▶ Ethical Deliberation in ART
 - ▶ [Dignum, 2017]
- ▶ Programming Machine Ethics
 - ▶ [Pereira&Saptawijaya, 2016]
- ▶ ...

Adressiert Forderungen nach Transparenz, Erklärbarkeit, Verifizierbarkeit:

- “Ethics Guidelines for Trustworthy AI” [HLEG, EC, April 2019]
- “Strategie Künstliche Intelligenz” [Bundesregierung, November 2018]

Beweise in der Künstlichen Intelligenz



Beweise in der Künstlichen Intelligenz



Beweise in der Künstlichen Intelligenz



Beweise in der Künstlichen Intelligenz



Beweise in der Künstlichen Intelligenz

A background image showing a humanoid robot with a metallic, reflective head and a man in a white shirt. They are standing in a room with a red wall. The robot is on the left, and the man is on the right, facing each other. The robot's head is turned towards the man. The man is holding a small object in his hand. The overall scene suggests a human-robot interaction or a demonstration of artificial intelligence.

Was wir brauchen:

Deduktive Kontrolle von ethischen & rechtlichen Vorgaben

Auf was wir uns nicht (alleine!) verlassen sollten:

Reine Daten- und Experiment-getriebene KI

Verschiedene Arten von Beweisen

Empirie (empirische Evidenz basierend auf Daten & Experimenten)

versus

Deduktion (scharfe, formal-logische Argumentation)

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

... wir können abbrechen und extrapolieren: Satz gilt!

Empirischer Beweis — Physiker mögen das!

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, durch experimentieren und hingucken)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

... wir können abbrechen und extrapolieren: Satz gilt!

(Hinweis: Maschinelles Lernen ist dem recht ähnlich!)

Deduktiver Beweis — Kuchenrezept (als Analogie)

Mehl

Zucker

Öl

Milch

Hefe

...


Butter

Zutaten


Streuselkuchen

Resultat

Deduktiver Beweis — Kuchenrezept (als Analogie)



Deduktiver Beweis — Kuchenrezept (als Analogie)



Deduktiver Beweis — Mathematik

$A \cup B := \dots$

$A \cap B := \dots$

$A \subseteq B \Leftrightarrow \dots$

$A = B := \dots$

$\dots$

$\dots$

Logik-Regeln

Annahmen

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

Theorem

Deduktiver Beweis — Mathematik

$$A \cup B := \dots$$

$$A \cap B := \dots$$

$$A \subseteq B \Leftrightarrow \dots$$

$$A = B := \dots$$

...

...

Logik-Regeln

Annahmen

Beweisschritte



Theorem

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

Deduktiver Beweis — Mathematik


$$A \cup B := \dots$$
$$A \cap B := \dots$$
$$A \subseteq B \Leftrightarrow \dots$$
$$A=B:=\dots$$

...

...

Logik-Regeln


Annahmen


$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

Beweisschritte

Theorem

Deduktiver Beweis — Mathematik



Deduktiver Beweis — (Ontologischer) Gottesbeweis

$Gott(x) := \dots$

Positive Eigenschaften

Essent. Eigenschaften

Notwendige Existenz

...

...

(Modal)Logik-Regeln

Annahmen

$\Box \exists x G(x)$ — Notwendigerweise existiert Gott

Theorem

Deduktiver Beweis — (Ontologischer) Gottesbeweis

$Gott(x) := \dots$

Positive Eigenschaften

Essent. Eigenschaften


Notwendige Existenz

...

...

(Modal)Logik-Regeln

Annahmen



Beweisschritte

$\Box \exists x G(x)$ — Notwendigerweise existiert Gott

Theorem

Deduktiver Beweis — (Ontologischer) Gottesbeweis

$Gott(x) := \dots$

Positive Eigenschaften

Essent. Eigenschaften

Notwendige Existenz

...

...


(Modal)Logik-Regeln

Annahmen

Unser Theorembeweiser Leo-III:

... kann sogar solche Gottesbeweise automatisch finden und bestätigen (oder auch widerlegen)

Beweisschritte



$\Box \exists x G(x)$ — Notwendigerweise existiert Gott

Theorem

Deduktiver Beweis — (Ontologischer) Gottesbeweis

$Gott(x) := \dots$

Positive Eigenschaften

Essent. Eigenschaften

Notwendige Existenz

... ..

(Modal)Logik-Regeln

Annahmen

Was wir 'eigentlich' erreicht haben:

... Automatisierung komplexer nicht-klassischer Logiken

... viele Anwendungen: KI, Philosophie, Mathematik, NL

Beweisschritte



$\Box \exists x G(x)$ — **Notwendigerweise existiert Gott**

Theorem

Deduktiver Beweis — Kontrolle von IASs

rechtlich-erlaubt(x) := ...

ethisch-ok(x) := ...

usw.

...

...


(Deontische)Logik-Regeln

Annahmen

x ist rechtlich und ethisch unbedenklich

Theorem

Deduktiver Beweis — Kontrolle von IASs



Normatives Schließen

Herausforderungen: Welche Logik(en)? Welche Ethik(en)?

- ▶ Dilemmas, Paradoxien, Inkompatible Theorien, etc.
- ▶ Geeignete Modellierung des Begriffs der **Obligation**
- ▶ Problem: Contrary-to-duty (**CTD**) Szenarien

Normatives Schließen

Herausforderungen: Welche Logik(en)? Welche Ethik(en)?

- ▶ Dilemmas, Paradoxien, Inkompatible Theorien, etc.
- ▶ Geeignete Modellierung des Begriffs der **Obligation**
- ▶ Problem: Contrary-to-duty (**CTD**) Szenarien

Standard CTD Struktur (Chisholm)

1. obligatorisch ' a '
2. obligatorisch 'falls a dann b '
3. wenn 'nicht a ' dann obligatorisch ' b '
4. 'nicht a ' (in gegebener Situation)

Gefahr: Paradox/Inkonsistenz— Ex falso quodlibet!

Normatives Schließen

Herausforderungen: Welche Logik(en)? Welche Ethik(en)?

- ▶ Dilemmas, Paradoxien, Inkompatible Theorien, etc.
- ▶ Geeignete Modellierung des Begriffs der **Obligation**
- ▶ Problem: Contrary-to-duty (**CTD**) Szenarien

CTD Beispiel (X. Parent): EU GDPR

1. Personal data shall be processed lawfully. (Art. 5)
E.g., the data subject must have given consent to the processing. (Art. 6/1.a)
2. **Implizit:** The data shall be kept, for the agreed purposes, if processed lawfully.
3. If personal data has been processed unlawfully, the controller has the obligation to erase the personal data in question without delay. (Art. 17.d, right to be forgotten)
4. **Gegebene Situation:** Some personal data has been processed unlawfully.

Gefahr: Paradox/Inkonsistenz — Ex falso quodlibet!


Normatives Schließen

Herausforderungen: Welche Logik(en)? Welche Ethik(en)?


- ▶ Dilemmas, Paradoxien, Inkompatible Theorien, etc.
- ▶ Geeignete Modellierung des Begriffs der **Obligation**
- ▶ Problem: Contrary-to-duty (**CTD**) Szenarien

Deontische Logik


- ▶ Schließen über Verpflichtungen, Erlaubnisse, Befugnisse
- ▶ Es gibt aber bisher keine 'beste' Logik:
 - ▶ Standard Deontische Logic
 - ▶ Dyadische Deontic Logik
 - ▶ Input/Output Logic
 - ▶ STIT-Logik
 - ▶ ...




Experimentierplattform für Normatives Schließen und Maschinen-Ethik




Experimentierplattform für Normatives Schließen und Maschinen-Ethik



Experimentierplattform für Normatives Schließen und Maschinen-Ethik



Experimentierplattform für Normatives Schließen und Maschinen-Ethik



Experimentierplattform für Normatives Schließen — Demo

The screenshot displays the 'GDPR.thy' experiment platform interface. The main window shows a theorem prover session with the following code:

```
1 theory GDPR imports SDL (* Christoph Benzmüller & Xavier Parent, 2018 *)
2
3 begin (** GDPR Example **)
4   consts process_data_lawfully::o erase_data::o kill_boss::o
5
6   axiomatization where
7     (* It is an obligation to process data lawfully. *)
8     A1: "[0(process_data_lawfully)]" and
9     (* Implicit: It is an obligation to keep the data if it was processed lawfully. *)
10    Implicit: "[0(process_data_lawfully → ¬erase_data)]" and
11    (* If data was not processed lawfully, then it is an obligation to erase the data. *)
12    A2: "[¬process_data_lawfully → 0(erase_data)]"
13    (* Given a situation where data is processed unlawfully. *) and
14    A3: "[¬process_data_lawfully]..".
15
16  (** Some Experiments **)
17  lemma True nitpick [satisfy] oops (* Consistency-check: Is there a model? *)
18  lemma False sledgehammer oops (* Inconsistency-check: Can Falsum be derived? *)
19
20  lemma "[0(erase_data)]" sledgehammer nitpick oops (* Should the data be erased? *)
21  lemma "[0(¬erase_data)]" sledgehammer nitpick oops (* Should the data be kept? *)
22  lemma "[0(kill_boss)]" sledgehammer nitpick oops (* Should the boss be killed? *)
23 end
```

The interface includes a sidebar on the right with tabs for 'Documentation', 'Sidekick', 'State', and 'Theories'. Below the code editor, there is a control bar with 'Proof state', 'Auto update', 'Update', and 'Search' buttons, along with a progress indicator at 100%.

The output window at the bottom shows the results of the experiments:

```
Sledgehammering...
Proof found...
"spass": The prover derived "False" from "A1", "A2", "A3", "D", and "Implicit", which could
"e": The prover derived "False" from "A1", "A2", "A3", "D", and "Implicit", which could be
"cvc4": Try this: by (metis A1 A2 A3 D Implicit) (68 ms)
"x3": Try this: by (metis A1 A2 A3 D Implicit) (59 ms)
```

The bottom of the interface has tabs for 'Output', 'Query', 'Sledgehammer', and 'Symbols'.


Experimentierplattform für Normatives Schließen — Demo

```
1 theory GDPR imports SDL                                (* Christoph Benzmüller & Xavier Parent, 2018 *)
2
3 begin (** GDPR Example **)
4 consts process_data_lawfully::o erase_data::o kill_boss::o
5
6 axiomatization where
7   (* It is an obligation to process data lawfully. *)
8   A1: "[O(process_data_lawfully)]" and
9   (* Implicit: It is an obligation to keep the data if it was processed lawfully. *)
10  Implicit: "[O(process_data_lawfully → ¬erase_data)]" and
11  (* If data was not processed lawfully, then it is an obligation to erase the data. *)
12  A2: "[¬process_data_lawfully → O(erase_data)]"
13  (* Given a situation where data is processed unlawfully. *) and
14  A3: "[¬process_data_lawfully].."
15
16 (*
17  (*
18  (*
19  (*
20  (*
21  lemma "[O(¬erase_data)]" sledgehammer nitpick oops (* Should the data be kept? *)
22  lemma "[O(kill_boss)]" sledgehammer nitpick oops (* Should the boss be killed? *)
23 end
```

Gefahren-Zone:
Paradoxien and Inkonsistenzen!

Win-Win Situation:
Beidseitige Verifikation
(Logiken ↔ ethische/rechtliche Theorien)

Ethics



Ethics

Vorschlag: **KI-Zukunftslabor E-NoRMEs**

- ▶ **“Experiments in Normative Reasoning and Maschine-Ethics”**
 - Cloud-basierte Plattform für Universelles (Normatives) Schließen
 - Experimente in der Maschinen-Ethik
- ▶ **Interdisziplinär:** Deduktion, Theorembeweisen, Wissensrepräsentation, Maschinelles Lernen, Maschinen-Ethik, Formale Methoden, Formale Ethik/Philosophie, Autonome Fahrzeuge, Finance, Soziale Robotik, usw.
- ▶ **International**
- ▶ **Industriebeteiligungen**
- ▶ **Standort:** Berlin!

Ethics

Aktuelle Publikationen zum Vortrag:

- ▶ Designing Normative Theories of Ethical Reasoning: Formal Framework, Methodology, and Tool Support, 2019, <https://arxiv.org/abs/1903.10187>
- ▶ Harnessing Higher-Order (Meta-)Logic to Represent and Reason with Complex Ethical Theories, PRICAI, 2019, Url (preprint): <http://arxiv.org/abs/1804.02929>
- ▶ What is a Proof? What should it be?, 2019, Url (preprint): <http://dx.doi.org/10.13140/RG.2.2.13405.87521/1>
- ▶ Universal (Meta-)Logical Reasoning: Recent Successes, SCP, 2019, <http://dx.doi.org/10.1016/j.scico.2018.10.008>
- ▶ Universal (Meta-)Logical Reasoning: The Wise Men Puzzle (Isabelle/HOL Dataset), Data in Brief, 2019, <http://dx.doi.org/10.1016/j.dib.2019.103823>
- ▶ Computer Science and Metaphysics: A Cross-Fertilization, Open Philosophy, 2019, Url (preprint): <http://doi.org/10.13140/RG.2.2.25229.18403>
- ▶ Automating Free Logic in HOL, with an Experimental Application in Category Theory, JAR, 2019, <http://dx.doi.org/10.1007/s10817-018-09507-7>