


Künstliche Intelligenz — Bemerkungen/Eigene Position

Prof. Dr. Christoph Benzmüller

FU Berlin | U Luxemburg



JFK-Institut, 17. Dezember 2019

Künstliche Intelligenz — Bemerkungen/Eigene Position

Prof. Dr. Christoph Benzmüller

FU Berlin | U Luxemburg

“The development of full artificial intelligence could spell the end of the human race.” (S. Hawking)



“I am in the camp that is concerned about super intelligence.” (B. Gates)

“I think we should be very careful about AI. If I were to guess what our biggest existential threat is, it’s probably that.” (E. Musk)



Künstliche Intelligenz — Bemerkungen/Eigene Position

Prof. Dr. Christoph Benzmüller

ETH Zürich / Universität Wien

"The development of full artificial intelligence could spell the end of the human race." (S. Hawking)



"I am in the camp that is concerned about super intelligence." (B. Gates)

Panikmache? Oder ist da was dran?

"I think we should be very careful about AI. If I were to guess what our biggest existential threat is, it's probably that." (E. Musk)





Quelle: Ex Machina, R/D: Alex Garland, 2015

KI-Visionäre:



Aristoteles



R. Llull



G. W. Leibniz



A. Turing

Einige Eckdaten:

- ▶ 1956: Konferenz am Dartmouth College (New Hampshire) mit J. McCarthy, M. Minsky, A. Newell und H. Simon
- ▶ seit Mitte 70er: Aufbau von KI-Forschergruppen in Deutschland
- ▶ Anfang 80er: 5th Generation Projekt in Japan (450 million \$)
- ▶ 1983: Erste offizielle KI-Professur in Deutschland (Kaiserslautern)
- ▶ 1988: Gründung des Deutschen Forschungszentrums für Künstliche Intelligenz (DFKI), heute ca. 800 MA

KI-Sommer

Mitte 50er bis Mitte 70er

Anfang 80er bis Mitte/Ende 80er



KI-Winter

Mitte 70er bis Ende 70er

Mitte/Ende 80er bis Mitte 90er

Definitionsversuche gibt es viele — aber keinen Konsens

- ▶ *AI is the science and engineering of making intelligent machines, especially intelligent computer programs. It is related to the similar task of using computers to understand human intelligence, but AI does not have to confine itself to methods that are biologically observable. (McCarthy)*
- ▶ *The study of how to make computers do things at which, at the moment, people are better. (Rich and Knight)*
- ▶ ...

Definitionsversuche gibt es viele — aber keinen Konsens

- ▶ *AI is the science and engineering of making intelligent machines, especially intelligent computer programs. It is related to the similar task of using computers to understand human intelligence, but AI does not have to confine itself to methods that are biologically observable. (McCarthy)*
- ▶ *The study of how to make computers do things at which, at the moment, people are better. (Rich and Knight)*
- ▶ ...

Starke KI

Maschinen mit (mind.)
allgemeiner menschlicher
Intelligenz

vs.

Schwache/Angewandte KI

Eingeschränkte, 'clevere'
Systeme die Intelligenz
simulieren

Kognitive Simulation

Testen von Theorien zur
menschlichen Kognition
mithilfe von Computern

My own (working) definition of AI

Context dependent notion

Relative use: e.g., one animal is more intelligent than another one

Absolute use: comparison against mental capabilities of humans

Def.: Artificial Intelligence (Benzmüller, March 2019)

Science of computational technologies being developed to achieve and explain *intelligent* behaviour in machines.

Def.: Intelligence (Benzmüller, March 2019)

A collection of mental capabilities that enable an entity

1. to solve (or learn to solve) hard problems, —solve problems—
2. to successfully act in known, unknown and dynamic environments (requires perception, planning, agency, etc.), —master the unknown—
3. to reason abstractly, intuitively, rationally, while avoiding inconsistencies and self-contradiction, —rational&abstract—
4. to reflect upon itself and to adjust its reasoning with upper goals and norms, and —self-reflective—
5. to interact socially with other entities and to align own values and norms with those of a society for a greater good. —be social—

A: How to define AI?

Def.: Intelligence (Benzmüller, March 2019)

A collection of mental capabilities that enable an entity

1. to solve (or learn to solve) hard problems, —solve problems—
2. to successfully act in known, unknown and dynamic environments (requires perception, planning, agency, etc.), —master the unknown—
3. to reason abstractly, intuitively, rationally, while avoiding inconsistencies and self-contradiction, —rational&abstract—
4. to reflect upon itself and to adjust its reasoning with upper goals and norms, and —self-reflective—
5. to interact socially with other entities and to align own values and norms with those of a society for a greater good. —interact socially—

Remarks

- ▶ Chatbot Tay (later replaced by Zo) would not qualify as very intelligent
- ▶ 3.-5. enable IAS to identify and refuse malicious/nonsense training data.
- ▶ Example: I refused in my early economics lectures to accept the idea that “air” is a good example for a “free good” (societal costs is pollution)
- ▶ “Information” should also be handled with care: no free good

Was ist KI?

Perzeption / Wahrnehmung

- ▶ ... wie ist die Welt um uns herum gestaltet?

Maschinelles Lernen (Deep Learning, etc.)

- ▶ ... wie können wir Modelle dieser Realität aufbauen und anpassen?

Wissensrepräsentation, Kommunikation und Interaktion

- ▶ ... wie können wir Modelle der Umgebung repräsentieren, verarbeiten und kommunizieren?

Schließen

- ▶ ... wie können wir neues Wissen/Modelle ableiten aus gegebenem Wissen?

Planen

- ▶ ... explorieren von Handlungsoptionen in der virtuellen, simulierten Welt, zu einer Entscheidungsfindung kommen


Agieren/Handlungsausführung

- ▶ ... Manipulation der realen Welt, Ausführen von Handlungsentscheidungen


Unterstützungstechnologien

- ▶ ... Validierung und Verifikation, Sicherheit, ethische und soziale Aspekte, SW/HW-Plattform, ...


Yin und Yang der KI



Yin und Yang der KI — **Erfolge & Medienpräsenz**



Yin und Yang der KI — Erfolge & Medienpräsenz




Erfolge

- ▶ Spiele:
Go und Schach
- ▶ endliche
Problemdomäne
- ▶ Weltmeisterniveau
erreicht: AlphaGo
und AlphaZero

(subsymbolische KI)

Yin und Yang der KI — Erfolge & Medienpräsenz



Erfolge

- ▶ Spiele:
Go und Schach
- ▶ endliche
Problemdomäne
- ▶ Weltmeisterniveau
erreicht: AlphaGo
und AlphaZero

(subsymbolische KI)




Yin und Yang der KI — **Erfolge & Medienpräsenz**

Erfolge

- ▶ Mathe:
Zahlentheorie
- ▶ unendliche
Problemdomäne
- ▶ offene Probleme
zuletzt gelöst durch
SAT-Solver

(symbolische KI)



Erfolge

- ▶ Spiele:
Go und Schach
- ▶ endliche
Problemdomäne
- ▶ Weltmeisterniveau
erreicht: AlphaGo
und AlphaZero

(subsymbolische KI)




Yin und Yang der KI — Erfolge & Medienpräsenz

Erfolge

- ▶ Mathe:
Zahlentheorie
- ▶ unendliche
Problemdomäne
- ▶ offene Probleme
zuletzt gelöst durch
SAT-Solver

(symbolische KI)



Erfolge

- ▶ Spiele:
Go und Schach
- ▶ endliche
Problemdomäne
- ▶ Weltmeisterniveau
erreicht: AlphaGo
und AlphaZero

(subsymbolische KI)




Yin und Yang der KI

Erfolge

- ▶ Mathe:
Zahlentheorie
- ▶ unendliche
Problemdomäne
- ▶ offene Probleme
zuletzt gelöst durch
SAT-Solver

(symbolische KI)




Erfolge

- ▶ Spiele:
Go und Schach
- ▶ endliche
Problemdomäne
- ▶ Weltmeisterniveau
erreicht: AlphaGo
und AlphaZero

(subsymbolische KI)




Yin und Yang der KI — **Ungesunder Hype?!**



Yin und Yang der KI — **The Next (really) Big Thing?!**

Präzises Schließen
Abstraktion
Kausalität
Sprache
...


Korrelationen
Muster
Robustheit
Lernen
...



Yin und Yang der KI — **The Next (really) Big Thing?!**

Präzises Schließen
Abstraktion
Kausalität
Sprache
...


Korrelationen
Muster
Robustheit
Lernen
...



Yin und Yang der KI — The Next (really) Big Thing?!

Präzises Schließen
Abstraktion
Kausalität
Sprache
...


Korrelationen
Muster
Robustheit
Lernen
...



Yin und Yang der KI — The Next (really) Big Thing?!

Präzises Schließen
Abstraktion
Kausalität
Sprache
...


Korrelationen
Muster
Robustheit
Lernen
...



Yin und Yang der KI — The Next (really) Big Thing?!

Präzises Schließen
Abstraktion
Kausalität
Sprache
...


Korrelationen
Muster
Robustheit
Lernen
...



Yin und Yang der KI — The Next (really) Big Thing?!

Präzises Schließen
Abstraktion
Kausalität
Sprache
...

Korrelationen
Muster
Robustheit
Lernen
...




Datengetriebene 'Beweise' in der Mathematik ???

Präzises Schließen
Abstraktion
Kausalität
Sprache

...

Korrelationen
Muster
Robustheit
Lernen

...



Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

... wir brechen hier ab und extrapolieren: Satz gilt!

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

... wir brechen hier ab und extrapolieren: Satz gilt!

1. Herausforderung: **Primzahl-Eigenschaft entdecken!**

Datengetriebene 'Beweise' in der Mathematik ???

Behauptung:

Jede ungerade Zahl (> 1) ist eine Primzahl

Beweis: (empirisch, datengetrieben)

3 - Primzahl.

5 - Primzahl.

7 - Primzahl.

~~9 - Messfehler.~~

11 - Primzahl.

13 - Primzahl.

... wir brechen hier ab und extrapolieren: Satz gilt!

1. Herausforderung: **Primzahl-Eigenschaft entdecken!**

2. Herausforderung: **Primzahl-Eigenschaft erklären!**

Deduktiver Beweis — Mathematik

$A \cup B := \dots$

$A \cap B := \dots$

$A \subseteq B \Leftrightarrow \dots$

$A = B := \dots$

$\dots$

$\dots$

Logik-Regeln

Annahmen

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

Theorem

Deduktiver Beweis — Mathematik

$$A \cup B := \dots$$

$$A \cap B := \dots$$

$$A \subseteq B \Leftrightarrow \dots$$

$$A = B := \dots$$

...

...

Logik-Regeln

Annahmen


Beweisschritte



Theorem

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

Deduktiver Beweis — Mathematik



Deduktiver Beweis — Mathematik

$A \cup B := \dots$

$A \cap B := \dots$

$A \subseteq B \Leftrightarrow \dots$

$A = B := \dots$

$\dots$

$\dots$

Logik-Regeln

Annahmen

Theorembeweiser:

Computerprogramme ...

... die solche Beweise vollautomatisch suchen

Unser Beweiser LEO-III ist weltweit führend ...

... für (polymorphe) Logik höherer Stufe

Weitere Anwendungen: Verifikation von ...

... Software/Hardware (Informatik)

... Rationale Argumente (Philosophie)

Beweisschritte

Theorem

Deduktiver Beweis — Mathematik

$$A \cup B := \dots$$

$$A \cap B := \dots$$

$$A \subseteq B \Leftrightarrow \dots$$

$$A = B := \dots$$

...

...

Logik-Regeln

Annahmen

Theorembeweiser:

Computerprogramme
... die solche

Unser Beweiser LEO-
... für (polymodale)

Weitere Anwendungen
... Software/Hardware
... Rationale Axiome

[Home](#) | [Video](#) | [Themen](#) | [Forum](#) | [English](#) | [DER SPIEGEL](#) | [SPIEGEL TV](#) | [Abo](#) | [Shop](#)

[RSS](#) | [Mobile](#) | [Newsletter](#)

SPIEGEL ONLINE INTERNATIONAL

[Sign in](#) | [Register](#)

[Front Page](#) | [World](#) | [Europe](#) | [Germany](#) | [Business](#) | [Zeitgeist](#) | [Newsletter](#)

[English Site](#) » [Germany](#) » [Science](#) » [Scientists Use Computer to Mathematically Prove Gödel God Theorem](#)

Holy Logic: Computer Scientists 'Prove' God Exists

By David Knight



Austrian mathematician Kurt Gödel kept his proof of God's existence a secret for decades. Now two scientists say they have proven it mathematically using a computer.

Two scientists have formalized a theorem regarding the existence of God penned by mathematician Kurt Gödel. But the God angle is somewhat of a red herring -- the real step forward is the example it sets of how computers can make scientific progress simpler.

‘Beweise’ in der Künstlichen Intelligenz



‘Beweise’ in der Künstlichen Intelligenz



Komplexitätssteigerung auf mehreren Ebenen:

komplexe, interagierende traditionelle Software
zunehmender Einsatz von datengetriebener KI

‘Beweise’ in der Künstlichen Intelligenz

Adversarial Attacks:



“panda”

57.7% confidence

$+ .007 \times$



noise

=



“gibbon”

99.3% confidence

Example of an adversarial perturbation (Goodfellow et al., 2015)

‘Beweise’ in der Künstlichen Intelligenz

Was wird eigentlich gelernt?



person

0.88



person

0.90



Predictions from convolutional DNN on images of Kim Kardashian (Bourdakos, 2017)

‘Beweise’ in der Künstlichen Intelligenz



‘Beweise’ in der Künstlichen Intelligenz



Wenn es schief geht brauchen wir:

präzise Erklärungen und Identifikation von Kausalitäten
verlässliche Klärung von Verantwortung und Haftbarkeit

‘Beweise’ in der Künstlichen Intelligenz



‘Beweise’ in der Künstlichen Intelligenz

Superintelligenz:

Superintelligenz noch nicht in Sicht

leicht überzogene Erwartungen an datengetriebene KI

sehr hohe Dynamik im Gebiet



'Beweise' in der Künstlichen Intelligenz

Superintelligenz:

Superintelligenz noch nicht in Sicht
leicht überzogene Erwartungen an datengetriebene KI
sehr hohe Dynamik im Gebiet

Gerade deshalb sind die Herausforderungen groß:

Trustworthy AI made in Germany/Europe

‘Beweise’ in der Künstlichen Intelligenz

Superintelligenz:

Superintelligenz noch nicht in Sicht
leicht überzogene Erwartungen an datengetriebene KI
sehr hohe Dynamik im Gebiet

Gerade deshalb sind die Herausforderungen groß:

Trustworthy AI made in Germany/Europe

Was wir brauchen (in kritischen Anwendungen):

deduktive Kontrolle von ethischen-rechtlichen Vorgaben
weil: “Erlernen” solcher Vorgaben ist problematisch

Erhaltung von Leben — Eine moralische Maxime von Maschinen?

Pilot über die Boeing 737 Max

SPIEGEL

"Eine Automatisierung will nicht überleben. Wir schon"



Uwe Harter ist seit 26 Jahren Pilot von Passagierflugzeugen. Er steuert A320-Jets - das Pendant von Airbus zur Boeing 737. Ein Gespräch über Notfälle im Cockpit und die Schulung der Crew. Von Claus Hecking **mehr...**

737 Max: FBI schließt sich offenbar Ermittlungen wegen Zulassung an
Abstürze der Boeing 737 Max: Welche Rolle spielten die Piloten?

- ▶ Können KI Systeme eine *eigene Ethik* entwickeln? —**Ich bezweifle das!**—
- ▶ Können KI System durch *unsere ethischen Prinzipien* kontrolliert werden? —**Möglicherweise, aber das ist nicht einfach!**—
- ▶ Lösung durch *"human in the loop"*? —**Wohl kaum!**—

Erhaltung von Leben — Eine moralische Maxime von Maschinen?

Pilot über die Boeing 737 Max

SPIEGEL

"Eine Automatisierung will nicht überleben. Wir schon"



Uwe Harter ist seit 26 Jahren Pilot von Passagierflugzeugen. Er steuert A320-Jets - das Pendant von Airbus zur Boeing 737. Ein Gespräch über Notfälle im Cockpit und die Schulung der Crew. Von Claus Hecking **mehr...**

737 Max: FBI schließt sich offenbar Ermittlungen wegen Zulassung an
Abstürze der Boeing 737 Max: Welche Rolle spielten die Piloten?

- ▶ Können KI Systeme eine *eigene Ethik* entwickeln? —**Ich bezweifle das!**—
- ▶ Können KI System durch *unsere ethischen Prinzipien* kontrolliert werden? —**Möglicherweise, aber das ist nicht einfach!**—
- ▶ Lösung durch *"human in the loop"*? —**Wohl kaum!**—

Erhaltung von Leben — Eine moralische Maxime von Maschinen?

Pilot über die Boeing 737 Max

SPIEGEL

"Eine Automatisierung will nicht überleben. Wir schon"



Uwe Harter ist seit 26 Jahren Pilot von Passagierflugzeugen. Er steuert A320-Jets - das Pendant von Airbus zur Boeing 737. Ein Gespräch über Notfälle im Cockpit und die Schulung der Crew. *Von Claus Hecking mehr...*

737 Max: FBI schließt sich offenbar Ermittlungen wegen Zulassung an
Abstürze der Boeing 737 Max: Welche Rolle spielten die Piloten?

- ▶ Können KI Systeme eine *eigene Ethik* entwickeln? —**Ich bezweifle das!**—
- ▶ Können KI System durch *unsere ethischen Prinzipien* kontrolliert werden? —**Möglicherweise, aber das ist nicht einfach!**—
- ▶ Lösung durch *“human in the loop”*? —**Wohl kaum!**—

Moral Machine Experiment (siehe Nature, vol. 563)


ARTICLE

<https://doi.org/10.1038/nature13601>

The Moral Machine experiment

Edmond Awad¹, Sohail Dsouza¹, Richard Kim¹, Jonathan Schulz¹, Joseph Dennis¹, Arim Shariff^{1,2}, Jean-François Rousseau^{1*} & Iyad Rahwan^{1,3*}

With the rapid development of artificial intelligence have come concerns about how machines will make moral decisions, and the major challenge of quantifying societal expectations about the ethical principles that should guide machine behaviour. To address this challenge, we deployed the Moral Machine, an online experimental platform designed to explore the moral dilemmas faced by autonomous vehicles. This platform gathered 40 million decisions in ten languages from millions of people in 233 countries and territories. Here we describe the results of this experiment. First, we summarize global moral preferences. Second, we document individual variations in preferences, based on respondents' demographics. Third, we report cross-cultural ethical variation, and uncover three major clusters of countries. Fourth, we show that these differences correlate with modern institutions and deep cultural traits. We discuss how these preferences can contribute to developing global, socially acceptable principles for machine ethics. All data used in this article are publicly available.



Präferenzen — Einige Beispiele:

Global: Menschen vor Tieren, mehr-Leben vor weniger-Leben, jünger vor älter

Gender: Frauen vor Männern (bei beiden Geschlechtern)

Kultur: 'jünger vor älter' Leben weniger stark ausgeprägt in Asien

Länder: 'Status vor kein-Status' höher ausgeprägt in reichen Ländern

Teilweise im Widerspruch zu den Empfehlungen in:


C. Luetge, **The German Ethics Code for automated and connected driving.**

Philos. Technol. 30, 547–558 (2017).

Ethics

Koexistenz mit **Intelligenten Autonomen Systemen (IASs)**?


- ▶ geeignete **Kontrollmechanismen** für IASs
- ▶ geeignete Form der **Mensch-Maschinen-Interaktion**



Ethics

Koexistenz mit **Intelligenten Autonomen Systemen (IASs)**?

- ▶ geeignete **Kontrollmechanismen** für IASs
- ▶ geeignete Form der **Mensch-Maschinen-Interaktion**




Existierende gesellschaftliche Prozesse basieren auf:


- ▶ **Erklärungen, rationaler Argumentation & Dialog,**
- ▶ inklusive **explizitem normativem Schließen** (rechtlich & ethisch)


Entwicklung von IASs ohne solche Kompetenzen? Wie sinnvoll?





IAS


















Pseudo-Ethischer KI Agent



Trustworthy AI

Verwandte Arbeiten

- ▶ Artificial Moral Agents
 - ▶ [Wallach&Allen, 2008]
- ▶ Ethical Governors
 - ▶ [ArkinEtAl., 2009, 2012]
 - ▶ [Dennis&Fisher, 2017]
- ▶ Ethical Deliberation in ART
 - ▶ [Dignum, 2017]
- ▶ Programming Machine Ethics
 - ▶ [Pereira&Saptawijaya, 2016]

Adressiert Forderungen nach Transparenz, Erklärbarkeit, Verifizierbarkeit:

- “Ethics Guidelines for Trustworthy AI” [HLEG, EC, April 2019]
- “Policy and Investment Recommend. for Trustworthy AI” [HLEG, EC, June 2019]
- “Strategie Künstliche Intelligenz” [Bundesregierung, November 2018]

Bedeutung

Bundesregierung, Nov 2018: Strategie Künstliche Intelligenz

*“Ethische und rechtsstaatliche Anforderungen sollten als integraler Bestandteil — und damit Markenzeichen einer „AI made in Europe“ — im gesamten Prozess der Entwicklung und Anwendung von KI Beachtung finden. Dies umfasst die Forschung, Entwicklung und die Produktion von KI, aber auch den Einsatz, den Betrieb, die **Kontrolle und die Governance KI-basierter Anwendungen**. Die Entwicklung von Verfahren zur Kontrolle und Nachvollziehbarkeit algorithmischer Entscheidungen sollte alle Akteure, inkl. Industrie, einbeziehen.”*

https://www.bmbf.de/files/Nationale_KI-Strategie.pdf; page 40

Ben Goertzel, CEO SingularityNET (zuvor Hanson Robotics); Nov 2018: “Toward Democratic, Lawful Citizenship for AIs, Robots, and Corporations”

*“Being an effective citizen of a nation operating under rule of law requires a form of general intelligence that combines formal linguistic and symbolic knowledge (the legal code) with the ability to abstract patterns from multimodal sensory data and informal linguistic data (corresponding to actual real-life situations to which the law needs to be applied). So an AI Citizenship Test needs to be a particular form of a General Intelligence Test. And it needs to be a test that stresses one of the most interesting issues at the core of modern AI R&D: **the fusion of symbolic and subsymbolic knowledge.**”*

<https://tinyurl.com/y8h94ouv>

Bedeutung

Bundesregierung, Nov 2018: Strategie Künstliche Intelligenz

*“Ethische und rechtsstaatliche Anforderungen sollten als integraler Bestandteil — und damit Markenzeichen einer „AI made in Europe“ — im gesamten Prozess der Entwicklung und Anwendung von KI Beachtung finden. Dies umfasst die Forschung, Entwicklung und die Produktion von KI, aber auch den Einsatz, den Betrieb, die **Kontrolle und die Governance KI-basierter Anwendungen**. Die Entwicklung von Verfahren zur Kontrolle und Nachvollziehbarkeit algorithmischer Entscheidungen sollte alle Akteure, inkl. Industrie, einbeziehen.”*

https://www.bmbf.de/files/Nationale_KI-Strategie.pdf; page 40



Ben Goertzel, CEO SingularityNET (zuvor Hanson Robotics); Nov 2018: “Toward Democratic, Lawful Citizenship for AIs, Robots, and Corporations”

*“Being an effective citizen of a nation operating under rule of law requires a form of general intelligence that combines formal linguistic and symbolic knowledge (the legal code) with the ability to abstract patterns from multimodal sensory data and informal linguistic data (corresponding to actual real-life situations to which the law needs to be applied). So an AI Citizenship Test needs to be a particular form of a General Intelligence Test. And it needs to be a test that stresses one of the most interesting issues at the core of modern AI R&D: **the fusion of symbolic and subsymbolic knowledge.**”*

<https://tinyurl.com/y8h94ouv>

Pseudo-Ethischer KI Agent

Trustworthy AI



Normatives Schließen

Herausforderungen: Welches Recht? Welche Ethik? **Welche Logik(en)?**

- ▶ Dilemmas, Paradoxien, inkompatible Theorien, etc.
- ▶ Geeignete Modellierung des Begriffs der **Obligation**
- ▶ **Obligation:** nicht-trivialer $\Box$ -Operator der Modallogik/Deontischen Logik
- ▶ Problem: “Contrary-to-duty” (**CTD**) Szenarien

Standard CTD Struktur (Chisholm)

1. obligatorisch ' a '
2. obligatorisch 'falls a dann b '
3. wenn 'nicht a ' dann obligatorisch ' b '
4. 'nicht a ' (in gegebener Situation)

Gefahr: Paradoxie/Inkonsistenz— Ex falso quodlibet!

Normatives Schließen


Herausforderungen: Welches Recht? Welche Ethik? **Welche Logik(en)?**

- ▶ Dilemmas, Paradoxien, inkompatible Theorien, etc.
- ▶ Geeignete Modellierung des Begriffs der **Obligation**
- ▶ **Obligation:** nicht-trivialer $\square$ -Operator der Modallogik/Deontischen Logik
- ▶ Problem: “Contrary-to-duty” (**CTD**) Szenarien


CTD Beispiel (X. Parent): **EU GDPR**

1. Personal data shall be processed lawfully. (Art. 5)
E.g., the data subject must have given consent to the processing. (Art. 6/1.a)
2. **Implizit:** The data shall be kept, for the agreed purposes, if processed lawfully.
3. If personal data has been processed unlawfully, the controller has the obligation to erase the personal data in question without delay. (Art. 17.d, right to be forgotten)
4. **Gegebene Situation:** Some personal data has been processed unlawfully.


Gefahr: Paradoxie/Inkonsistenz — Ex falso quodlibet!




Experimentierplattform für Normatives Schließen und Maschinen-Ethik




Experimentierplattform für Normatives Schließen und Maschinen-Ethik



Experimentierplattform für Normatives Schließen und Maschinen-Ethik



Experimentierplattform für Normatives Schließen und Maschinen-Ethik



Experimentierplattform für Normatives Schließen — Demo möglich!

The screenshot displays the Isabelle/HOL Sledgehammer interface. The main window shows a theory file named `GDPR.thy` with the following content:

```
1 theory GDPR imports SDL (* Christoph Benzmüller & Xavier Parent, 2018 *)
2
3 begin (** GDPR Example **)
4   consts process_data_lawfully:: $\sigma$  erase_data:: $\sigma$  kill_boss:: $\sigma$ 
5
6   axiomatization where
7     (* It is an obligation to process data lawfully. *)
8     A1: "[0(process_data_lawfully)]" and
9     (* Implicit: It is an obligation to keep the data if it was processed lawfully. *)
10    Implicit: "[0(process_data_lawfully  $\rightarrow$   $\neg$ erase_data)]" and
11    (* If data was not processed lawfully, then it is an obligation to erase the data. *)
12    A2: "[ $\neg$ process_data_lawfully  $\rightarrow$  0(erase_data)]"
13    (* Given a situation where data is processed unlawfully. *) and
14    A3: "[ $\neg$ process_data_lawfully]"
15
16  (** Some Experiments **)
17  lemma True nitpick [satisfy] oops (* Consistency-check: Is there a model? *)
18  lemma False sledgehammer oops (* Inconsistency-check: Can False be derived? *)
19
20  lemma "[0(erase_data)]" sledgehammer nitpick oops (* Should the data be erased? *)
21  lemma "[0( $\neg$ erase_data)]" sledgehammer nitpick oops (* Should the data be kept? *)
22  lemma "[0(kill_boss)]" sledgehammer nitpick oops (* Should the boss be killed? *)
23 end
```

The right sidebar shows the project structure with "Documentation", "Sidekick", "State", and "Theories". The bottom panel shows the Sledgehammer output:

```
Sledgehammering...
Proof found...
"spass": The prover derived "False" from "A1", "A2", "A3", "D", and "Implicit", which could
"e": The prover derived "False" from "A1", "A2", "A3", "D", and "Implicit", which could be d
"cvc4": Try this: by (metis A1 A2 A3 D Implicit) (68 ms)
"z3": Try this: by (metis A1 A2 A3 D Implicit) (59 ms)
```

The bottom of the interface includes tabs for "Output", "Query", "Sledgehammer", and "Symbols".

Isabelle/HOL (Beweisassistent) als Werkzeug für Universelles Schließen

Experimentierplattform für Normatives Schließen — Demo möglich!

The screenshot shows the Sledgehammer IDE interface with a file named `GDPR.thy` open. The file path is `~/chris/trunk/tex/talks/2018-DEON/DEMO/`. The code contains the following:

```
1 theory GDPR imports SDL (* Christoph Benzmüller & Xavier Parent, 2018 *)
2
3 begin (** GDPR Example **)
4   consts process_data_lawfully:: $\sigma$  erase_data:: $\sigma$  kill_boss:: $\sigma$ 
5
6   axiomatization where
7     (* It is an obligation to process data lawfully. *)
8     A1: " $\Box$ (process_data_lawfully)" and
9     (* Implicit: It is an obligation to keep the data if it was processed lawfully. *)
10    Implicit: " $\Box$ (process_data_lawfully  $\rightarrow$   $\neg$ erase_data)" and
11    (* If data was not processed lawfully, then it is an obligation to erase the data. *)
12    A2: " $\Box$ ( $\neg$ process_data_lawfully  $\rightarrow$   $\Box$ (erase_data))"
13    (* Given a situation where data is processed unlawfully. *) and
14    A3: " $\Box$ ( $\neg$ process_data_lawfully)"
15
16  (** Some Experiments **)
17  lemma True nitpick fastforce none (* Consistency check: Is there a model? *)
18  |
19  |
20  |
21  |
22  |
23 end
```

An orange warning box is overlaid on the code, containing the text:

Gefahren-Zone:
Paradoxien und Inkonsistenzen!

At the bottom of the IDE, there are checkboxes for "Proof state" and "Auto update", an "Update" button, a search bar, and a zoom level set to "100%".

Parallele Entwicklung und Verifikation von
ethisch-rechtlichen Theorien $\leftrightarrow$ passende Logikformalismen

Isabelle/HOL (Beweisassistent) als Werkzeug für Universelles Schließen

Formalisierung einer Ethischen Theorie: Alan Gewirth's "PGC"

"Act in accord with the generic rights of your recipients as well as of yourself. I shall call this the **Principle of Generic Consistency** (PGC), since it combines the formal consideration of consistency with the material consideration of rights to the generic features or goods of action."
(Alan Gewirth, **Reason and Morality**, 1978)

Abwandlung & Erweiterung der **Goldenen Regel**:

"Behandle andere so, wie du von ihnen behandelt werden willst."

"Was du nicht willst, dass man dir tu', das füg auch keinem andern zu."

Referenzen

- ▶ A. Gewirth. Reason and morality. U of Chicago Press, 1978. (401 pages)
- ▶ D. Beyleveld. The dialectical necessity of morality: An analysis and defense of Alan Gewirth's argument to the principle of generic consistency. U of Chicago Press, 1991. (523 pages)
- ▶ A. Kornai. Bounding the impact of AGI. J. Experimental & Theoretical AI, 2014.

Formalisierung einer Ethischen Theorie: Alan Gewirth's "PGC"

"Act in accord with the generic rights of your recipients as well as of yourself. I shall call this the **Principle of Generic Consistency** (PGC), since it combines the formal consideration of consistency with the material consideration of rights to the generic features or goods of action."
(Alan Gewirth, *Reason and Morality*, 1978)

Abwandlung & Erweiterung der **Goldenen Regel**:

"Behandle andere so, wie du von ihnen behandelt werden willst."

"Was du nicht willst, dass man dir tu', das füg auch keinem andern zu."



FORMALISATION AND EVALUATION OF ALAN GEWIRTH'S PROOF FOR THE PRINCIPLE OF GENERIC CONSISTENCY IN ISABELLE/HOL

Title:

Formalisation and Evaluation of Alan Gewirth's Proof for the Principle of Generic Consistency in Isabelle/HOL

Authors:

David Fuenmayor (davfuenmayor /at/ gmail /dot/ com) and [Christoph Benz Müller](#)

[Home](#)

Formalisierung einer Ethischen Theorie: Alan Gewirth's "PGC"

"Act in accord with the generic rights of your recipients as well as of yourself. I shall call this the **Principle of Generic Consistency** (PGC), since it combines the formal consideration of consistency with the material consideration of rights to the generic features or goods of action."
(Alan Gewirth, *Reason and Morality*, 1978)

Abwandlung & Erweiterung der **Goldenen Regel**:

*"Behandle andere so, wie du von ihnen behandelt werden willst."
"Was du nicht willst, dass man dir tu", das füg auch keinem andern zu."*



FORMALISATION AND EVALUATION OF ALAN GEWIRTH'S PROOF FOR THE PRINCIPLE OF GENERIC CONSISTENCY IN ISABELLE/HOL

Springer Link

[Pacific Rim International Conference on Artificial Intelligence](#)

PRICAI 2019: [PRICAI 2019: Trends in Artificial Intelligence](#) pp 418-432 | [Cite as](#)

Harnessing Higher-Order (Meta-)Logic to Represent and Reason with Complex Ethical Theories

Authors

[Authors and affiliations](#)

David Fuenmayor Christoph Benzmüller

Home

Formalisierung einer Ethischen Theorie: Alan Gewirth's "PGC"

"Act in accord
call this the **Pr**
consideration
features or god

f. I shall
e formal
generic
y, 1978)

A
"Behandl
"Was du nic

llst."
ern zu."



[Home](#)

BACHELOR'S THESIS

Modelling the US Constitution in HOL

On establishing a dictatorship with Gödel

Valeria Zahoransky

supervised and examined by
Prof. Dr. Christoph BENZMÜLLER


examined by
Prof. Dr. Jan VON PLATO
(University of Helsinki)

FOR

Ethics

Fazit

- ▶ KI Hype etwas einseitig überzogen; dennoch gilt ...
... KI-Technologie hat enormes, positives Potential.
- ▶ Vor den Problemen sollten wir nicht die Augen verschließen,
eine “deploy-and-then-regulate”-Mentalität ist nicht angebracht.
- ▶ Entsprechende Studien zur Kontrolle von KI-Systemen jetzt starten!
- ▶ Erforderliche interdisziplinäre Kompetenz jetzt aufbauen!



Vorschlag: KI-Zukunftslabor



Projekttitel: ENoRME: Explicit Normative Reasoning and Machine Ethics

Beantragte Laufzeit: 36 Monate

Angestrebter Standort: Berlin

Forschungs- und Entwicklungsvorhaben:

“Cloud-basierte on-demand” Plattform zur Modellierung und Automatisierung ethisch-rechtlicher Theorien

- ▶ Methoden- und Technologieentwicklung
Theorie—Entwurf—Implementierung—Anwendungsstudien
- ▶ Lehrveranstaltungen, Workshops, Konferenzen, Tutorien und e-Learning
- ▶ Öffentlichkeitsarbeit und Community Management
- ▶ Kooperation mit nationalen und internationalen KI-Initiativen

Vorschlag: KI-Zukunftslabor



- ▶ Methoden- und Technologieentwicklung
Theorie—Entwurf—Implementierung—Anwendungsstudien
- ▶ Lehrveranstaltungen, Workshops, Konferenzen, Tutorien und e-Learning
- ▶ Öffentlichkeitsarbeit und Community Management

Vorschlag: KI-Zukunftslabor



- ▶ Me...
 - ▶ Le...
 - ▶ Öffentlichkeitsarbeit und Community management
 - ▶ Kooperation mit nationalen und internationalen KI-Initiativen
- en
d e-Learning

Vorschlag: KI-Zukunftslabor



Mehrwert zu laufenden Forschungs- und Entwicklungsarbeiten:

“Interdisziplinäre Forschung an Schnittstellen”:

- (i) Automatisches Theorembeweisen und Deduktion
 - (ii) Universelles Logisches Schließen
 - (iii) Modellierung ethisch-rechtlicher Theorien und Normatives Schließen
 - (iv) Maschinen-Ethik
 - (v) Robotik
 - (vi) Maschinelles Lernen
-
- ▶ Bindeglied zwischen Forschung und Anwendung
 - ▶ Katalysator für praktische Entwicklungen
 - ▶ Internationales Netzwerk / Integration von Communities
 - ▶ Lehr-/Lernmaterial
 - ▶ Neue Generation von Wissenschaftlern

Vorschlag: KI-Zukunftslabor



Partizipierende Partnereinrichtungen und Wissenschaftler/innen:

FU Berlin: (1) C. Benz Müller, (2) Raúl Rojas, (3) Daniel Göhring

U Koblenz: (4) Claudia Schon (Uli Furbach)

U Luxembourg: (5) Xavier Parent, (6) Alexander Steen (Leon van der Torre)

U Bergen: (7) Marija Slavkovik

U Miami: (8) Geoff Sutcliffe

U Liverpool: (9) Louise Dennis (Michael Fisher)

U Campinas: (10) Walter Carnielli, (11) Juliana Bueno-Soler


U Buenos Aires: (12) Maria Vanina Martinez

Weitere akademische Partner: Toby Walsh (UNSW Sydney), Beishui Liao (Zhejiang U), Adam Pease (Infosys, Palo Alto), Jan Broersen (U Utrecht), Stephan Schulz (DHBW Stuttgart), Ralf Romeike (FU Berlin)

Industrie & Forschungseinrichtungen: Latentine GmbH, wizAI solutions GmbH, LuxAI S.A., KPMG Lighthouse Luxembourg, DLR;

Zusammenarbeit: Research Center MATH+; JFK-Institute

Vorschlag: KI-Zukunftslabor



Vorschlag: KI-Zukunftslabor



Besondere Eignung der Wissenschaftler/innen für ENoRME:

- (1) Universelles Schließen, Deduktionssysteme, Maschinen-Ethik
- (2) KI, Robotik, Maschinelles Lernen
- (3) Autonomes Fahren, Robotik, Maschinelles Lernen
- (4) Beschreibungslogiken, Theorembeweisen, Maschinen-Ethik, Ontologien
- (5) Normatives Schließen, Deontische Logiken, Ethisch-Rechtliche Theorien
- (6) Automatisches Theorembeweisen, Systementwicklung
- (7) Kollektives Schließen, Maschinen-Ethik
- (8) Infrastrukturen und Testumgebungen für Deduktionssysteme
- (9) Autonome Systeme, Verifizierbare Systeme, Maschinen-Ethik
- (10) Nichtklassische Logiken, Logikkombinationen, Parakonsistentes Schließen
- (11) Probalistisches Parakonsistentes Schließen
- (12) Schließen bei Unsicherheit & Inkonsistenz, Semantic Web

Vorschlag: KI-Zukunftslabor



Projektziele und erwartete Resultate:

- Cloud-basierte Werkbank und Infrastruktur
- Standardisierung und Benchmarking im Normativen Schließen
- Theorie und Implementierung neuer, relevanter Logikkombinationen
- Beispiele automatisierter ethisch-rechtlicher Theorien
- Spezielle Technologien (Beweisen und Modelle) im Normativen Schließen
- Agenten-basierte Simulationsplattform
- Fallstudien
- Entwurf und Modellierung von Architekturen für “Ethical Governors”
- Exemplarische Implementierungen:
 - (i) Autonome Fahrzeuge, (ii) Finanz- und Bankwesen, (iii) Soziale Robotik, (vi) Pharmazie and Gesundheitswesen, (v) Kognitive Robotik, (vi) Marketing
- Konferenzen, Workshops, und Tutorien
- Vorlesungen, Seminare, e-Learning, Projekte
- Öffentlichkeitsarbeit

Vorschlag: KI-Zukunftslabor



Projektziele und erwartete Resultate:

- Cloud-basierte Werkbank und Infrastruktur
- Standardisierung und Benchmarking im Normativen Schließen
- Theorie und Implementierung neuer, relevanter Logikkombinationen
- Beispiele automatisierter ethisch-rechtlicher Theorien
- Spezielle Technologien (Beweisen und Modelle) im Normativen Schließen
- Agenten
- Falls **... unfortunately funded by BMBF**
- Entwurf und Modellierung von Architekturen für "Ethical Governors"
- Exemplarische Implementierungen:
 - (i) Autonome Fahrzeuge, (ii) Finanz- und Bankwesen, (iii) Soziale Robotik, (vi) Pharmazie and Gesundheitswesen, (v) Kognitive Robotik, (vi) Marketing
- Konferenzen, Workshops, und Tutorien
- Vorlesungen, Seminare, e-Learning, Projekte
- Öffentlichkeitsarbeit

Ontologischer Gottesbeweis — Eine lange Tradition

Für und Wider

.....

Anselm v. C.	Th. Aquinas	Descartes	Hume	Hegel	Hartshorne
Gaunilo		Spinoza	Kant	Frege	Malcolm
		Leibniz			Lewis
					Plantinga
					Gödel

.....

Anselms Definition von Gott (Proslogion, 1078):

“Gott ist das, über das hinaus nichts gedacht werden kann.”

Kurt Gödel's Definition von Gott:


“Gott besitzt alle positiven Eigenschaften.”

Zu zeigen durch rationales Argumentieren:

“ Gott existiert.”

Ontologischer Gottesbeweis — Eine lange Tradition

Für und Wider



Anselms Definition von Gott (Proslogion, 1078):

“Gott ist das, über das hinaus nichts gedacht werden kann.”

Kurt Gödel's Definition von Gott:

“Gott besitzt alle positiven Eigenschaften.”

Zu zeigen durch rationales Argumentieren:

“Gott existiert notwendigerweise.”

Gödel's Manuscript: 1930's, 1941, 1946-1955, 1970

Scott's Version von Gödel's Gottesbeweis

Axiom A1 Entweder eine Eigenschaft oder ihre Negation ist positiv: $\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$

Axiom A2 Eine Eigenschaft, die notwendigerweise durch eine positive Eigenschaft impliziert wird, ist positiv: $\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$

Theorem T1 Positive Eigenschaften kommen möglicherweise einer existenten Entität zu: $\forall \phi. P(\phi) \rightarrow \Diamond \exists x. \phi(x)$

Definition D1 Eine *gottähnliche Entität* besitzt alle positiven Eigenschaften: $G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$

Axiom A3 Die Eigenschaft, gottähnlich zu sein, ist positiv: $P(G)$

Korollar C Möglicherweise existiert Gott $\Diamond \exists x. G(x)$

Axiom A4 Positive Eigenschaften sind notwendigerweise positiv: $\forall \phi. P(\phi) \rightarrow \Box P(\phi)$

Definition D2 Eine Eigenschaft ist *Essenz* einer Entität, falls sie der Entität zukommt und notwendigerweise alle Eigenschaften der Entität impliziert: $\phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$

Theorem T2 Gottähnlichkeit ist *Essenz* jeder gottähnlichen Entität: $\forall x. G(x) \rightarrow G \text{ ess. } x$

Definition D3 Eine Entität *existiert notwendigerweise*, wenn all ihre Essenzen notwendigerweise in einer existenten Entität realisiert sind:

$$NE(x) = \forall \phi. \phi \text{ ess. } x \rightarrow \Box \exists y. \phi(y)$$

Axiom A5 Notwendigerweise zu existieren ist eine positive Eigenschaft: $P(NE)$

Theorem T3 Gott existiert notwendigerweise: $\Box \exists x. G(x)$

Scott's Version von Gödel's Gottesbeweis

Axiom A1 Entweder eine Eigenschaft oder ihre Negation ist positiv: $\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$

Axiom A2 Eine Eigenschaft, die notwendigerweise durch eine positive Eigenschaft impliziert wird, ist positiv: $\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$

Theorem T1 Positive Eigenschaften kommen möglicherweise einer existenten Entität zu: $\forall \phi. P(\phi) \rightarrow \Diamond \exists x. \phi(x)$

Definition D1 Eine *gottähnliche Entität* besitzt alle positiven Eigenschaften:

$$G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$$

Axiom A3 Die Eigenschaft, gottähnlich zu sein, ist positiv: $P(G)$

Korollar C Möglicherweise existiert Gott $\Diamond \exists x. G(x)$

Axiom A4 Positive Eigenschaften sind notwendigerweise positiv: $\forall \phi. P(\phi) \rightarrow \Box P(\phi)$

Definition D2 Eine Eigenschaft ist *Essenz* einer Entität, falls sie der Entität zukommt und notwendigerweise alle Eigenschaften der Entität impliziert:

$$\phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$$

Theorem T2 Gottähnlichkeit ist *Essenz* jeder gottähnlichen Entität: $\forall x. G(x) \rightarrow G \text{ ess. } x$

Definition D3 Eine Entität *existiert notwendigerweise*, wenn all ihre Essenzen notwendigerweise in einer existenten Entität realisiert sind:

Axiom A5 Notwendige

Unterschied zu Gödel (der den Konjunkt vermeidet)

Theorem T3 Gott existiert

Scott's Version von Gödel's Gottesbeweis

Axiom A1 Entweder eine Eigenschaft oder ihre Negation ist positiv: $\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$

Axiom A2 Eine Eigenschaft, die notwendigerweise durch eine positive Eigenschaft impliziert wird, ist positiv: $\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$

Theorem T1 Positive Eigenschaften kommen möglicherweise einer existenten Entität zu: $\forall \phi. P(\phi) \rightarrow \Diamond \exists x. \phi(x)$

Definition D1 Eine *gottähnliche Entität* besitzt alle positiven Eigenschaften:

$$G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$$

Axiom A3 Die Eigenschaft, gottähnlich zu sein, ist positiv: $P(G)$

Korollar C Möglicherweise existiert Gott $\Diamond \exists x. G(x)$

Axiom A4 Positive Eigenschaften sind notwendigerweise positiv: $\forall \phi. P(\phi) \rightarrow \Box P(\phi)$

Definition D2 Eine Eigenschaft ist *Essenz* einer Entität, falls sie der Entität zukommt und notwendigerweise alle Eigenschaften der Entität impliziert: $\phi \text{ ess } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$

Theorem T2 Gottähnlichkeit ist *Essenz* jeder gottähnlichen Entität: $\forall x. G(x) \rightarrow G \text{ ess } x$

Definition D3 Eine Entität *existiert notwendigerweise*, wenn all ihre Essenzen notwendigerweise in einer existieren

Axiom A5 Notwendige

Theorem T3 Gott existiert

Modale Operatoren werden verwendet.
Diese modellieren **Notwendigkeit** und **Möglichkeit**.

Scott's Version von Gödel's Gottesbeweis

Axiom A1 Entweder eine Eigenschaft oder ihre Negation ist positiv:

$$\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$$

Axiom A2 Eine Eigenschaft, die notwendigerweise durch eine positive Eigenschaft impliziert wird, ist positiv:

$$\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$$

Theorem T1 Positive Eigenschaften kommen möglicherweise einer existenten Entität zu:

$$\forall \phi. P(\phi) \rightarrow \Diamond \exists x. \phi(x)$$

Definition D1 Eine *gottähnliche Entität* besitzt alle positiven Eigenschaften:

$$G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$$

Axiom A3 Die Eigenschaft, gottähnlich zu sein, ist positiv:

$$P(G)$$

Korollar C Möglicherweise existiert Gott

$$\Diamond \exists x. G(x)$$

Axiom A4 Positive Eigenschaften sind notwendigerweise positiv:

$$\forall \phi. P(\phi) \rightarrow \Box P(\phi)$$

Definition D2 Eine Eigenschaft ist *Essenz* einer Entität, falls sie der Entität zukommt und notwendigerweise alle Eigenschaften der Entität impliziert:

$$\phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$$

Theorem T2 Gottähnlichkeit ist *Essenz* jeder gottähnlichen Entität:

$$\forall x. G(x) \rightarrow G \text{ ess. } x$$

Definition D3 Eine Entität *existiert notwendigerweise*, wenn all ihre Essenzen notwendigerweise in einer existenten Entität realisiert sind:

$$NE(x) = \forall \phi. \phi \text{ ess. } x \rightarrow \Box \exists y. \phi(y)$$

Axiom A5 Notwendige

Theorem T3 Gott existiert

Allaussagen über Eigenschaften

Scott's Version von Gödel's Gottesbeweis — Demo

Axiom A1 Entweder eine Eigenschaft oder ihre Negation ist positiv: $\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$

Axiom A2 Eine Eigenschaft, die notwendigerweise durch eine positive Eigenschaft impliziert wird, ist positiv: $\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$

Theorem T1 Positive Eigenschaften kommen möglicherweise einer existenten Entität zu: $\forall \phi. P(\phi) \rightarrow \Diamond \exists x. \phi(x)$

Definition D1 Eine *gottähnliche Entität* besitzt alle positiven Eigenschaften: $G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$

Axiom A3 Die Eigenschaft, gottähnlich zu sein, ist positiv: $P(G)$

Korollar C Möglicherweise existiert Gott $\Diamond \exists x. G(x)$

Axiom A4 Positive Eigenschaften sind notwendigerweise positiv: $\forall \phi. P(\phi) \rightarrow \Box P(\phi)$

Definition D2 Eine Eigenschaft ist *Essenz* einer Entität, falls sie der Entität zukommt und notwendigerweise alle Eigenschaften der Entität impliziert: $\phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$

Theorem T2 Gottähnlichkeit ist *Essenz* jeder gottähnlichen Entität: $\forall x. G(x) \rightarrow G \text{ ess. } x$

Definition D3 Eine Entität *existiert notwendigerweise*, wenn all ihre Essenzen notwendigerweise in einer existenten Entität realisiert sind:

$$NE(x) = \forall \phi. \phi \text{ ess. } x \rightarrow \Box \exists y. \phi(y)$$

Axiom A5 Notwendigerweise zu existieren ist eine positive Eigenschaft: $P(NE)$

Theorem T3 Gott existiert notwendigerweise: $\Box \exists x. G(x)$

Scott's Version von Gödel's Gottesbeweis — Demo

Axiom A1

$$\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$$

Axiom A2

$$\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$$

Theorem T1

$$\forall \phi. P(\phi) \rightarrow \Diamond \exists x. \phi(x)$$

Definition D1

$$G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$$

Axiom A3

$$P(G)$$

Korollar C

$$\Diamond \exists x. G(x)$$

Axiom A4

$$\forall \phi. P(\phi) \rightarrow \Box P(\phi)$$

Definition D2

$$\phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$$

Theorem T2

$$\forall x. G(x) \rightarrow G \text{ ess. } x$$

Definition D3

$$NE(x) = \forall \phi. \phi \text{ ess. } x \rightarrow \Box \exists y. \phi(y)$$

Axiom A5

$$P(NE)$$

Theorem T3

$$\Box \exists x. G(x)$$

Scott's Version von Gödel's Gottesbeweis — Demo

Axiom A1

$$\forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$$

Axiom A2

$$\forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$$

Theorem T1

Definition D1

$$G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$$

Axiom A3

$$P(G)$$

Korollar C

Axiom A4

$$\forall \phi. P(\phi) \rightarrow \Box P(\phi)$$

Definition D2

$$\phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$$

Theorem T2

Definition D3

$$NE(x) = \forall \phi. \phi \text{ ess. } x \rightarrow \Box \exists y. \phi(y)$$

Axiom A5

$$P(NE)$$

Theorem T3

$$\Box \exists x. G(x)$$

Scott's Version von Gödel's Gottesbeweis — Demo

$$\mathbf{A1:} \forall \phi. P(\neg \phi) \leftrightarrow \neg P(\phi)$$

$$\mathbf{A2:} \forall \phi. \forall \psi. (P(\phi) \wedge \Box \forall x. \phi(x) \rightarrow \psi(x)) \rightarrow P(\psi)$$

$$\mathbf{D1:} G(x) = \forall \phi. P(\phi) \rightarrow \phi(x)$$

$$\mathbf{A3:} P(G)$$

$$\mathbf{A4:} \forall \phi. P(\phi) \rightarrow \Box P(\phi)$$

$$\mathbf{D2:} \phi \text{ ess. } x = \phi(x) \wedge (\forall \psi. \psi(x) \rightarrow \Box \forall y. \phi(y) \rightarrow \psi(y))$$

$$\mathbf{D3:} NE(x) = \forall \phi. \phi \text{ ess. } x \rightarrow \Box \exists y. \phi(y)$$

$$\mathbf{A5:} P(NE)$$

$$\mathbf{T3:} \Box \exists x. G(x)$$